

树的集成：GBDT

集成方法之提升方法

小胖

目录

ONE 梯度提升

源自梯度下降法的启发

TWO GBDT算法细节

模型步骤

THREE 模型的联结

Facebook的经验

梯度提升

一个简单的回归问题

回归问题

假设有数据集 $\{X, y\}$, 以及模型 F_0

$$\{\mathbf{X}_i, y_i\} \quad F_0(\mathbf{X}_i)$$

计算得到模型 F_0 的预测误差

$$r_i = y_i - F_0(\mathbf{X}_i)$$

从错误中学习

得到新的数据集 $\{X, r\}$, 训练模型 h_1

$$\{\mathbf{X}_i, r_i\} \quad h_1(\mathbf{X}_i)$$

F 和 h 可以认为是决策树模型

得到新的模型 F_1 , 预测效果比 F_0 好

$$F_1(\mathbf{X}_i) = F_0(\mathbf{X}_i) + h_1(\mathbf{X}_i)$$

$h_1 = 0$ 时, F_1 与 F_0 的
效果一致

依次递进, 得到效果更好的模型 F_k

$$F_k(\mathbf{X}_i) = F_{k-1}(\mathbf{X}_i) + h_k(\mathbf{X}_i)$$

梯度提升

数学表达



$$L = \frac{1}{n} \sum_i (\hat{y}_i - y_i)^2$$

损失函数

损失函数的梯度

$$\frac{\partial L}{\partial \hat{y}_i}(F_0(\mathbf{X}_i), y_i) = F_0(\mathbf{X}_i) - y_i = -r_i$$

计算得到模型 F_0 的预测误差

$$r_i = y_i - F_0(\mathbf{X}_i)$$

$$\{\mathbf{X}_i, -\frac{\partial L}{\partial \hat{y}_i}(F_0(\mathbf{X}_i), y_i)\} \quad \{\mathbf{X}_i, -\frac{\partial L}{\partial \hat{y}_i}(F_1(\mathbf{X}_i), y_i)\} \quad \dots \quad \{\mathbf{X}_i, -\frac{\partial L}{\partial \hat{y}_i}(F_{k-1}(\mathbf{X}_i), y_i)\}$$

$$h_1(\mathbf{X}_i) \quad h_2(\mathbf{X}_i) \quad \dots \quad h_k(\mathbf{X}_i)$$

$$F_1 = F_0 + h_1 \quad F_2 = F_1 + h_2 \quad \dots \quad F_k = F_{k-1} + h_k$$

梯度提升

梯度下降的启示

假设损失函数：

$$L = \frac{1}{n} \sum_{i=1}^n (y_i - ax_i - b)^2$$

随机选取起点
 (a_0, b_0) ：

$$\Delta L = L(a_1, b_1) - L(a_0, b_0)$$

$$\Delta L \approx \frac{\partial L(a_0, b_0)}{\partial a} \Delta a + \frac{\partial L(a_0, b_0)}{\partial b} \Delta b$$

如果令：

$$(\Delta a, \Delta b) = -\gamma \left(\frac{\partial L(a_0, b_0)}{\partial a}, \frac{\partial L(a_0, b_0)}{\partial b} \right)$$

$$\Delta L \approx -\gamma \left[\left(\frac{\partial L(a_0, b_0)}{\partial a} \right)^2 + \left(\frac{\partial L(a_0, b_0)}{\partial b} \right)^2 \right] \leq 0$$

得到迭代
公式：

$$a_{k+1} = a_k - \gamma \frac{\partial L(a_k, b_k)}{\partial a}, b_{k+1} = b_k - \gamma \frac{\partial L(a_k, b_k)}{\partial b}$$

假设损失函数：

$$L = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = L(\{\hat{y}_i\})$$

随机选取起点 $(\{\hat{y}_i\}_0)$ ：

$$\Delta L = L(\{\hat{y}_i\}_1) - L(\{\hat{y}_i\}_0)$$

$$\Delta L \approx \frac{\partial L(\{\hat{y}_i\}_0)}{\partial \hat{y}_1} \Delta \hat{y}_1 + \dots + \frac{\partial L(\{\hat{y}_i\}_0)}{\partial \hat{y}_n} \Delta \hat{y}_n$$

同样的证明过程

得到迭代
公式：

$$\{\hat{y}_i\}_{k+1} = \{\hat{y}_i\}_k - \gamma \frac{\partial L(\{\hat{y}_i\}_k)}{\partial \hat{y}_i}$$



梯度提升

$$F_{k+1} = F_k + h_{k+1}$$

梯度提升

梯度下降的启示

$$a_{k+1} = a_k - \gamma \frac{\partial L(a_k, b_k)}{\partial a}$$



$$\{\mathbf{X}_i, -\frac{\partial L}{\partial \hat{y}_i}(F_0(\mathbf{X}_i), y_i)\}$$

$$h_1(\mathbf{X}_i)$$

$$F_1 = F_0 + h_1$$

更新对象

模型参数

模型预测值

更新方法

损失函数对参数的
真实梯度值

模型对相应梯度的
预测值

理论基础

以损失函数下降速度
最快的方向更新模型参数

以模型效果上升速度
最快的方向更新模型预测值

目录

ONE 梯度提升

源自精度下降法的启发

TWO GBDT算法细节

模型步骤

THREE 模型的联结

Facebook的经验

GBDT算法细节

算法步骤

分类问题

$$L = \frac{1}{n} \sum_{i=1}^n y_i \ln(1 + e^{-\hat{y}_i}) + (1 - y_i) \ln(1 + e^{\hat{y}_i})$$

1

定义模型的损失函数

$$L = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 = L(\{\hat{y}_i\})$$

2

初始化预测值

$$F_0 = \frac{1}{n} \sum_i y_i$$

3

计算损失函数梯度
得到新的训练数据和更新模型

$$\{\mathbf{X}_i, -\frac{\partial L}{\partial \hat{y}_i}(F_0(\mathbf{X}_i), y_i)\} \quad \text{更新模型 } h_1$$

4

得到最优的更新力度
得到新的预测模型

$$\gamma_1 = \underset{\gamma}{\operatorname{argmin}} L(F_0 + \gamma h_1) \quad \text{新的预测模型 } F_1 = F_0 + \gamma_1 h_1$$

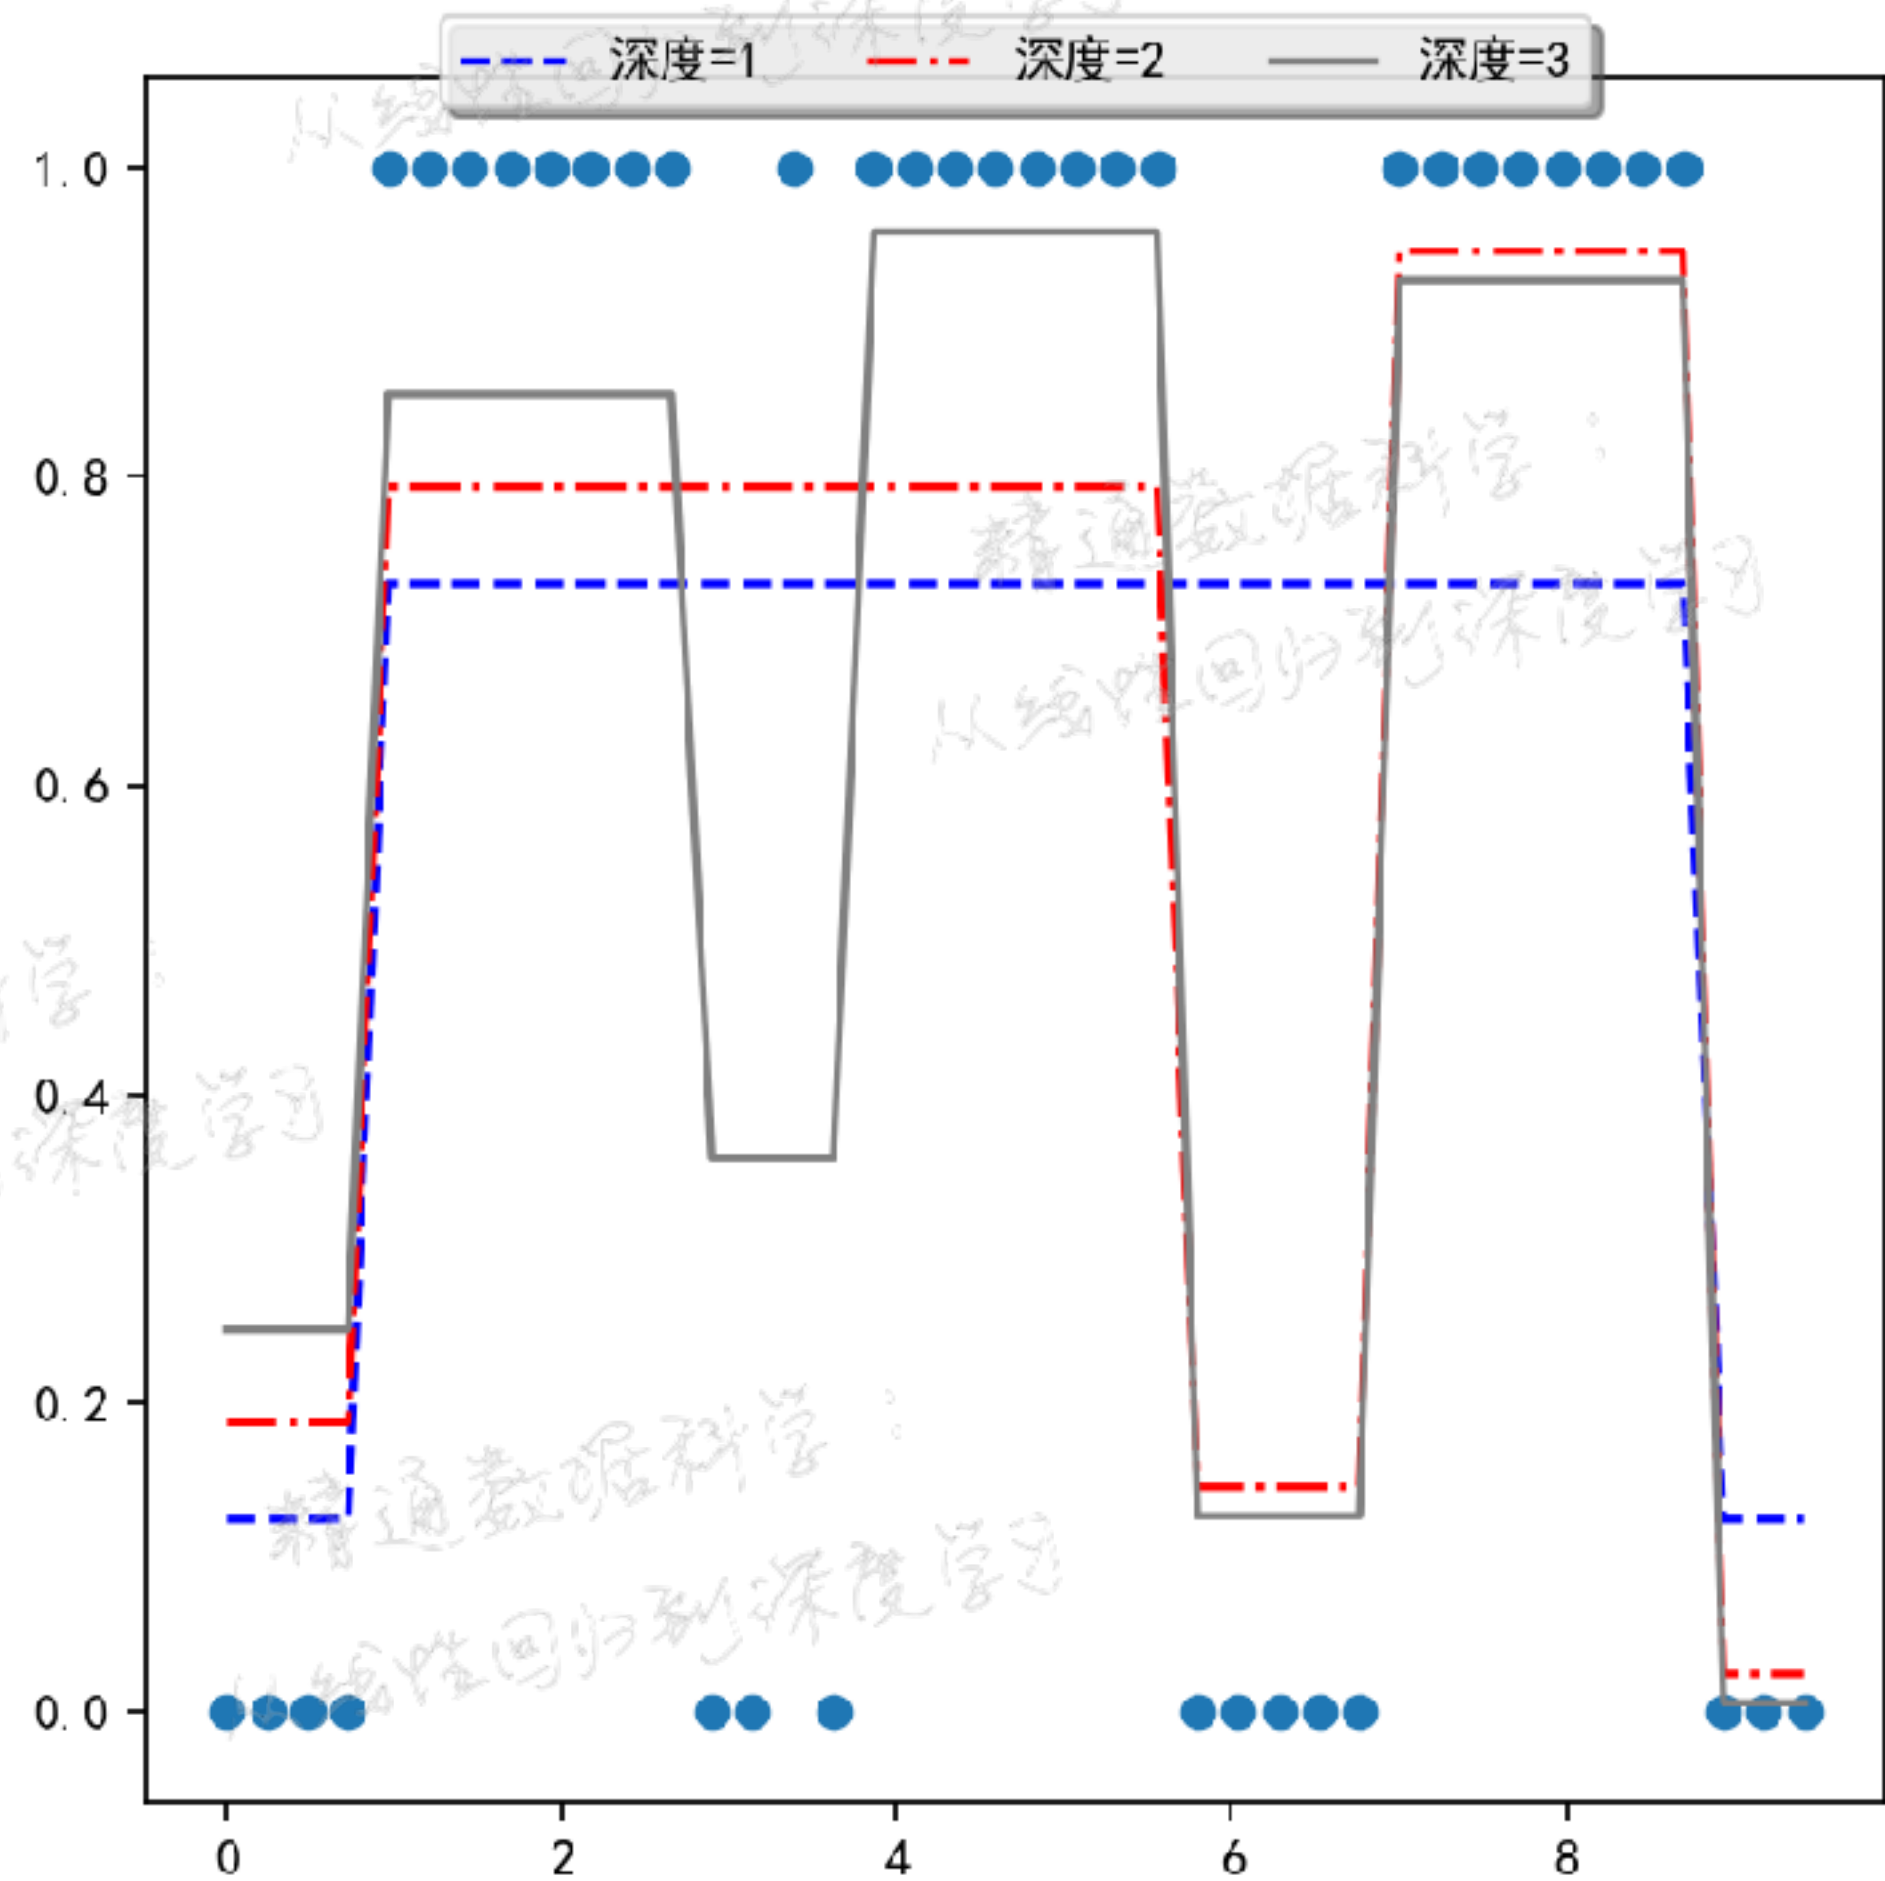
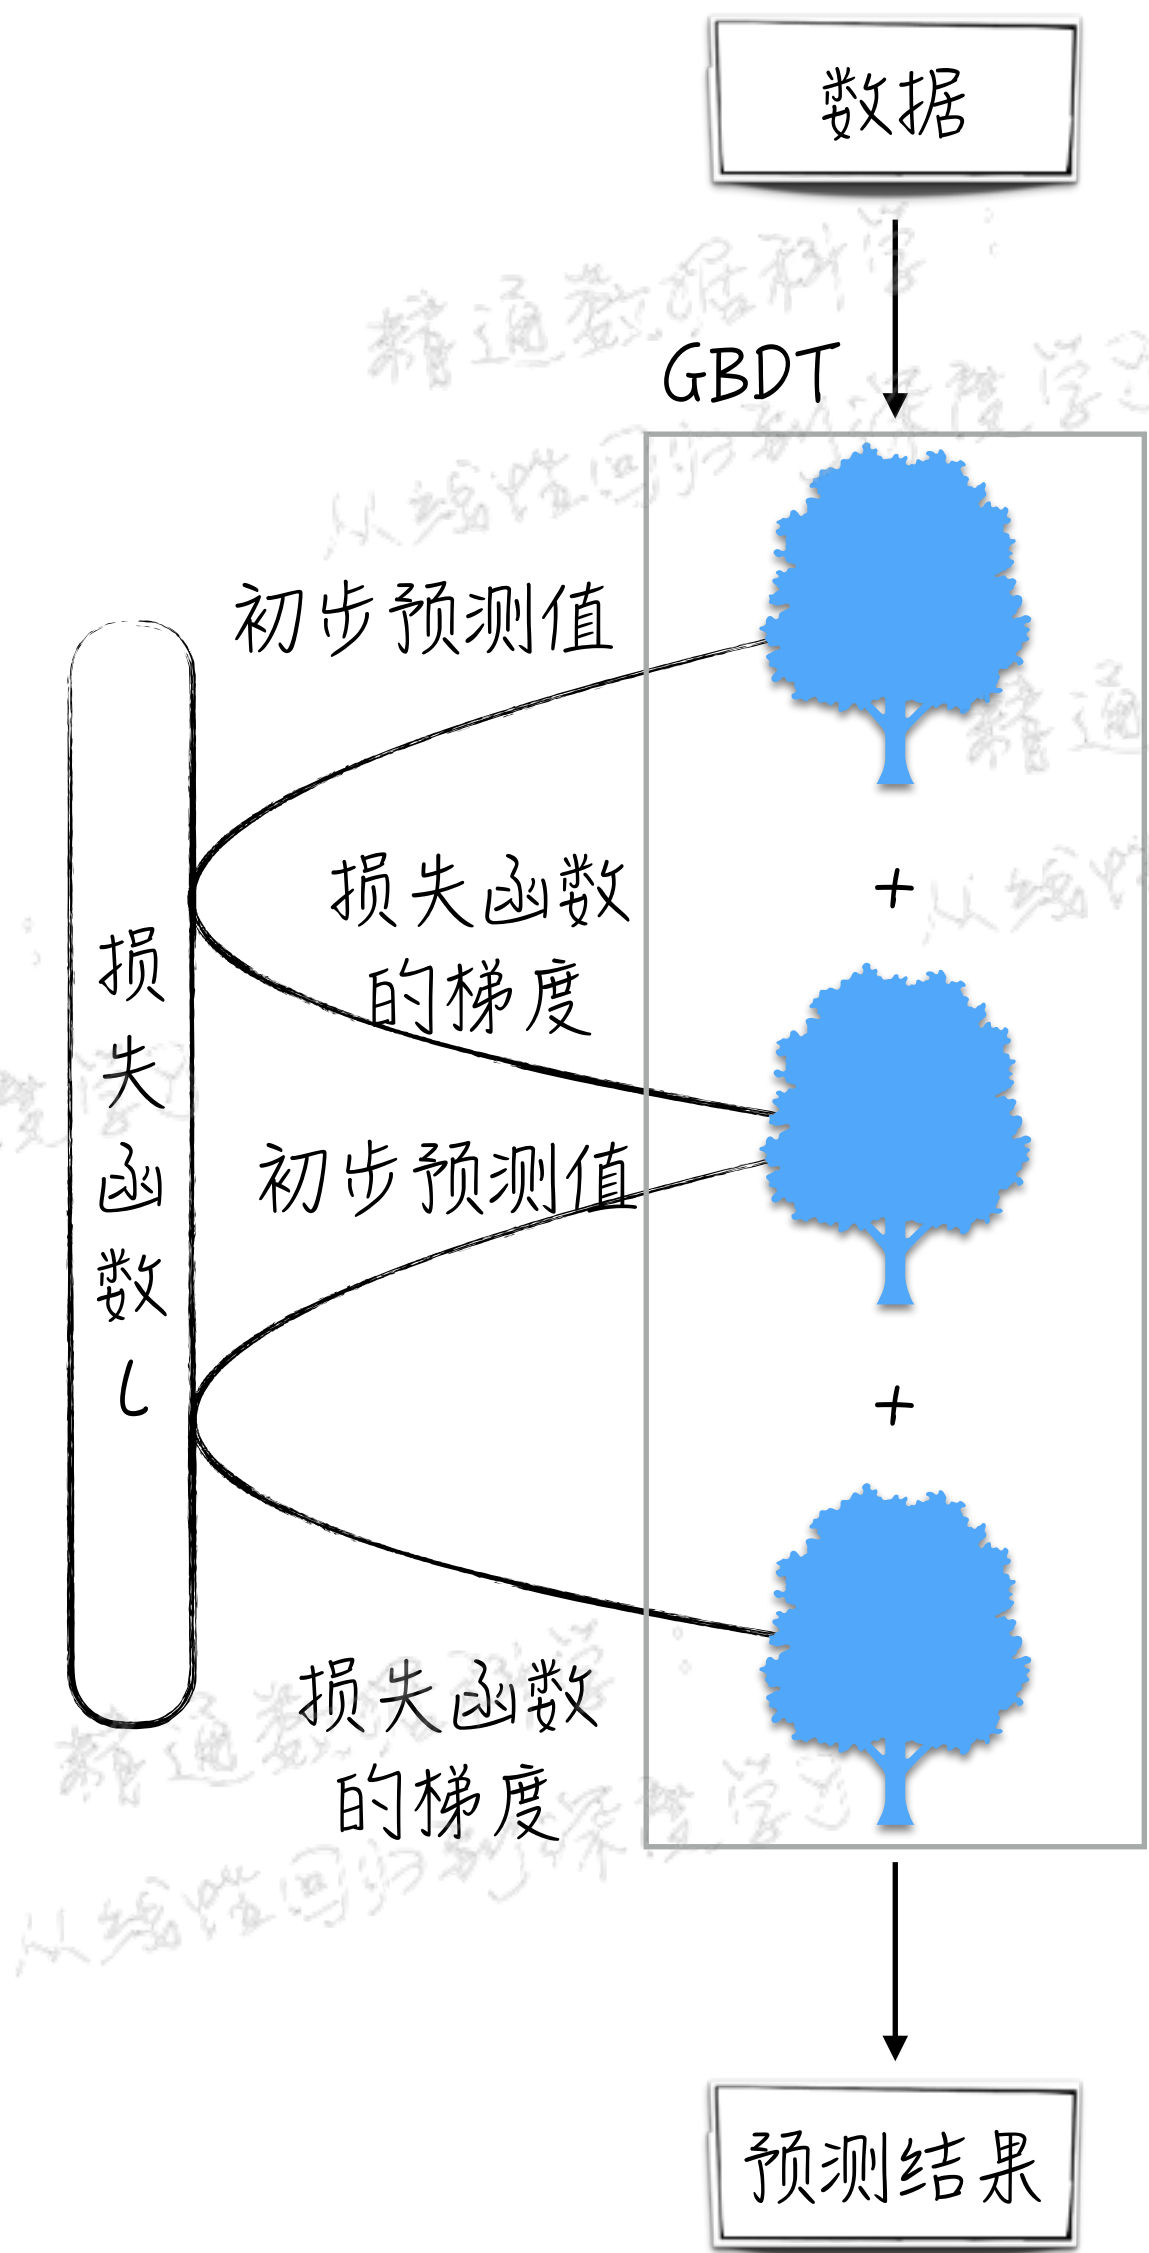
5

不断重复第3步和第4步

$$F_k = F_{k-1} + \gamma_k h_k$$

GBDT算法细节

模型结果



模型缺点



目录

ONE 梯度提升

源自精度下降法的启发

TWO GBDT 算法细节

模型步骤

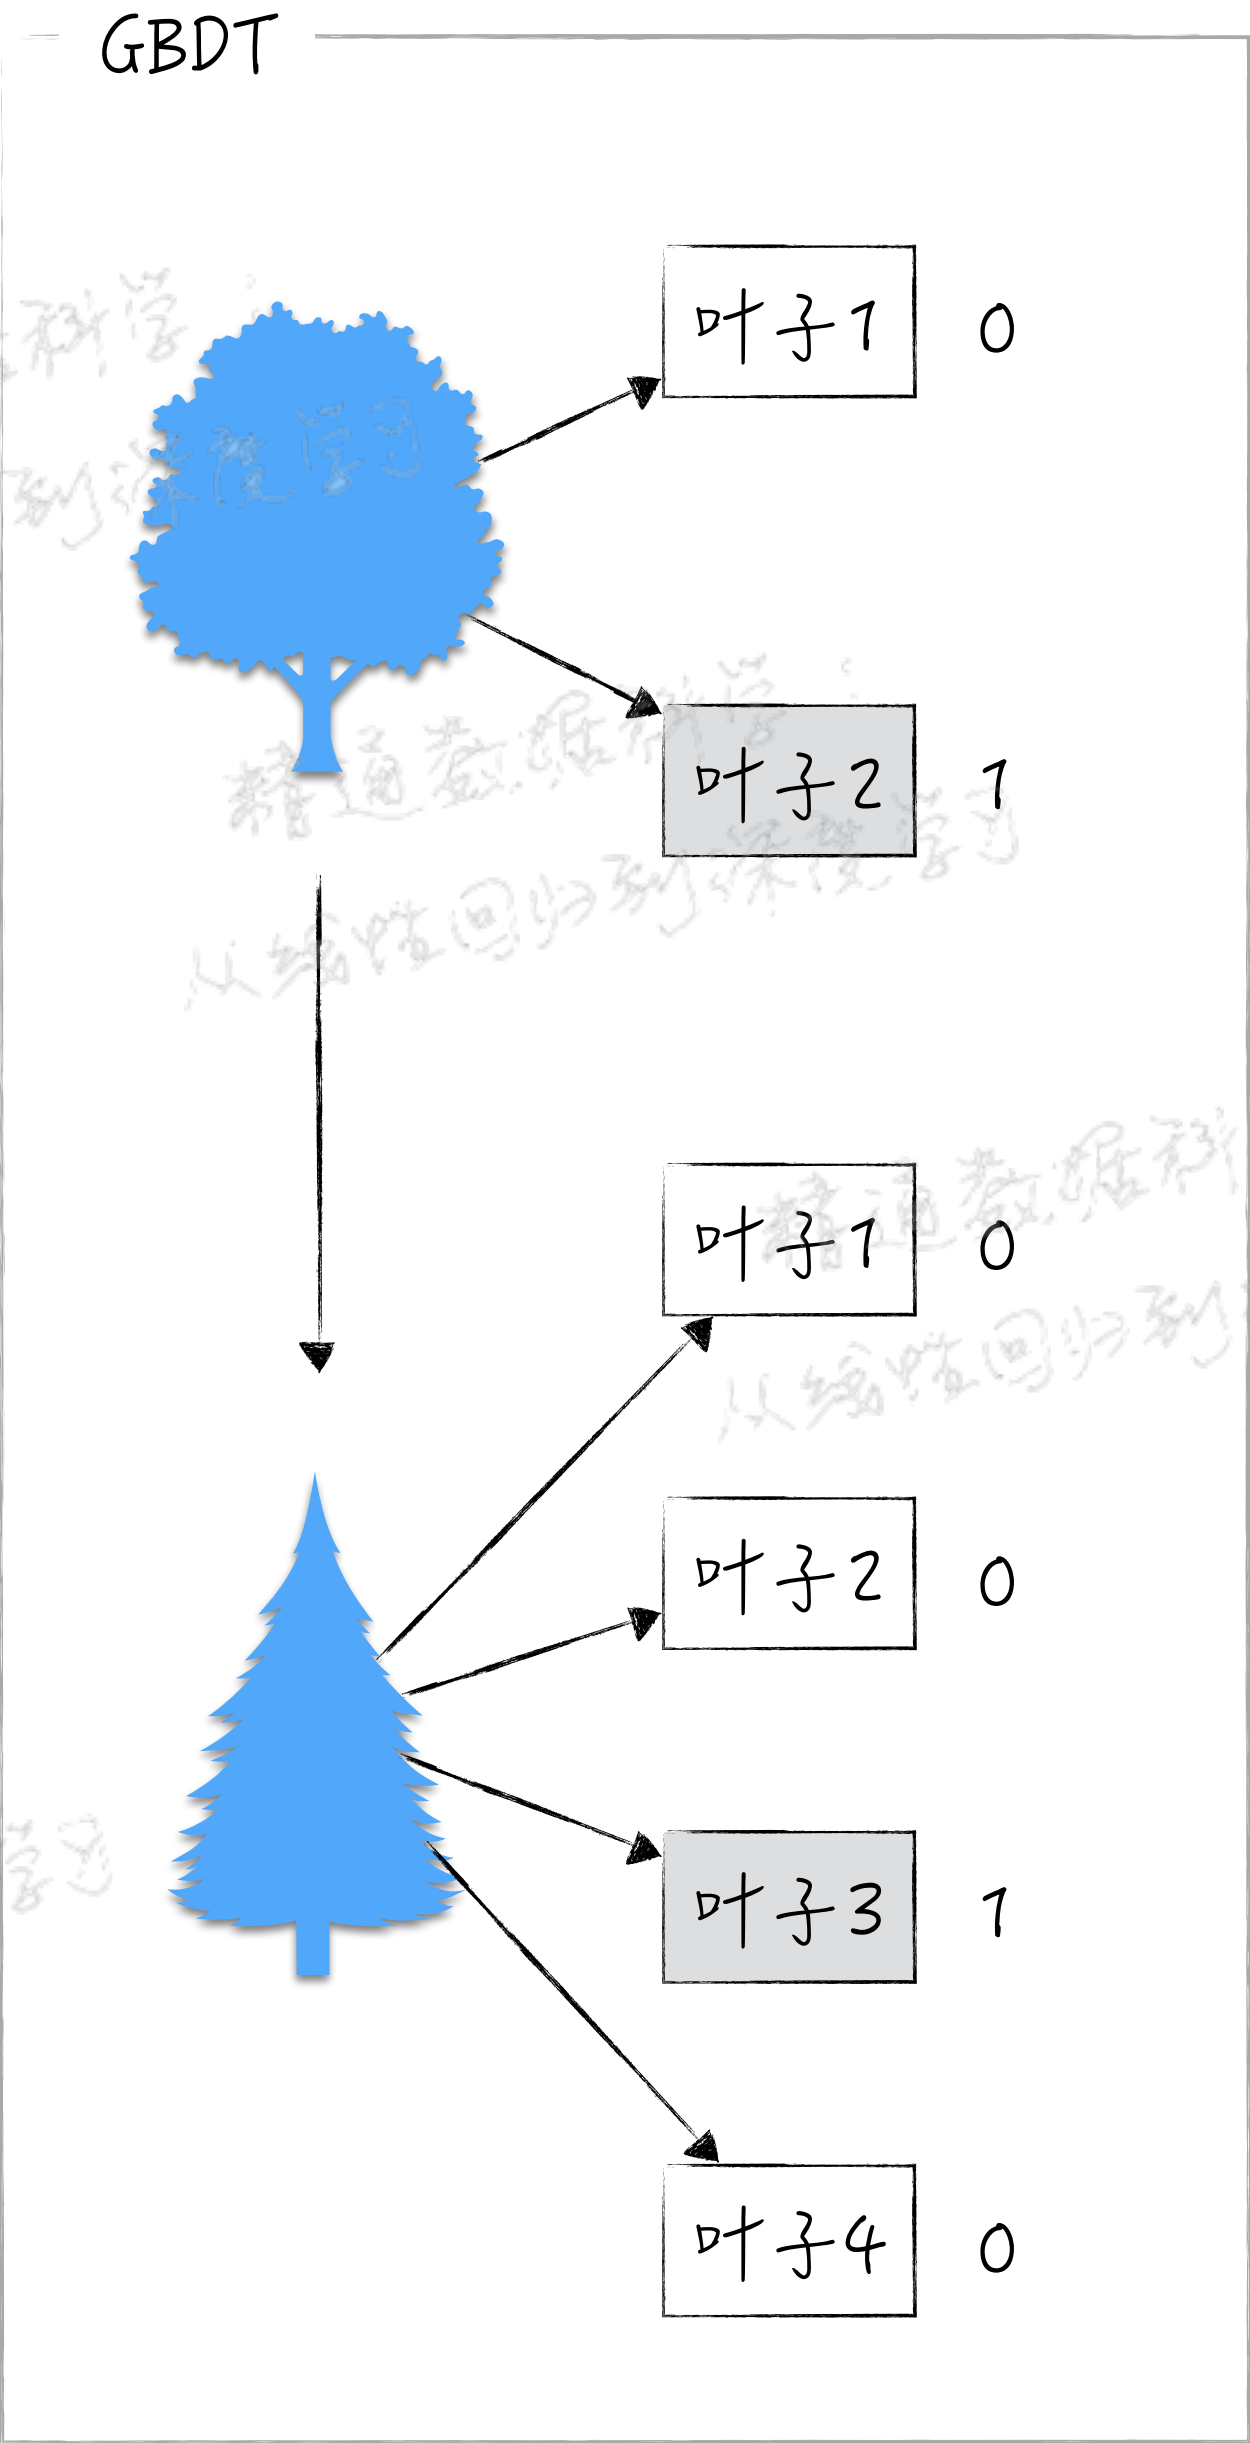
THREE 模型的联结

Facebook的经验

模型的联结

GBDT + LR

X_i



逻辑回归

享受逻辑回归的可解释性
+
惩罚项


利用GBDT做特征提取

模型的联结

模型效果

同样的数据，分别使用LR、GBDT、GBDT + LR
进行建模

GBDT + LR模型的效果更好



THANK YOU

精通数据挖掘科学：
从线性回归到深度学习